TABLAS HASH

Hashing: idea básica

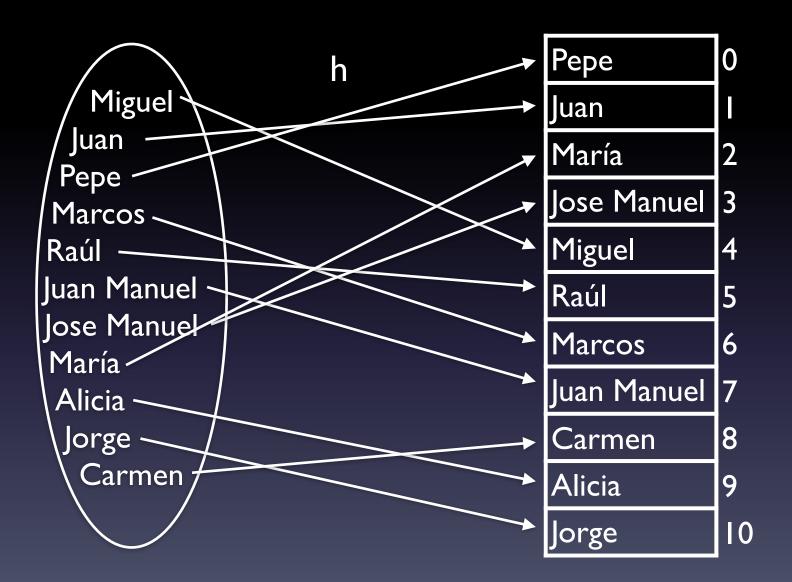
- El Hashing no opera mediante la comparación entre valores clave, sino buscando una función, h(k), que nos dé la localización exacta de la clave k en la estructura de datos en la que estén almacenadas las claves
- ¿Son fáciles de encontrar esas funciones h? NO
 - Si buscamos que \forall i \neq j \Rightarrow h(i) \neq h(j)
 - Tabla tamaño 40 y 30 claves
 40³0 ≈ 1.15×10⁴8 posibles funciones
 40!/10! ≈ 2.25×10⁴¹ no generan duplicados
 ¡¡¡Sólo nos servirían 2 de cada 10 millones!!!

Hashing: idea básica

- Los registros de datos a los que corresponden las claves suele estar almacenados en un fichero de un sistema de almacenamiento externo.
- La tabla Hash actúa a modo de índice

- Nuestro objetivo será:
 - Encontrar funciones h (funciones hash) que generen el menor número posible de colisiones
 - Diseñar métodos de resolución de colisiones, cuando éstas se produzcan

- Una tabla Hash es un contenedor asociativo (tipo diccionario) que permite un almacenamiento y posterior recuperación eficientes de elementos, denominados valores, a partir de otros objetos, llamados claves
- La forma ideal de realizar la búsqueda de un elemento en un contenedor sería aplicar una función matemática sobre el dato y que ésta devolviera directamente el lugar en el que se encuentra. Esto sería O(I)
- A esa función se le llama función Hash



Clave

Tabla Hash

0 23121 i

I 24576 n

i 23396 n-I

• • •

n-l 22563 l

21456 0

Fichero

0 21456 •••••

22563 ••••

23121

n-I

n

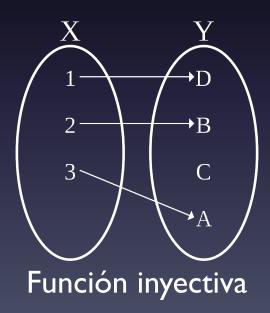
Clave 23396

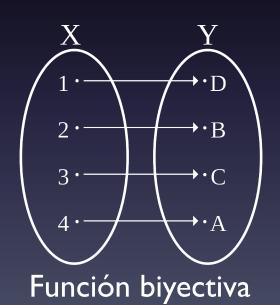
n

 $h(2\overline{3396}) = i$

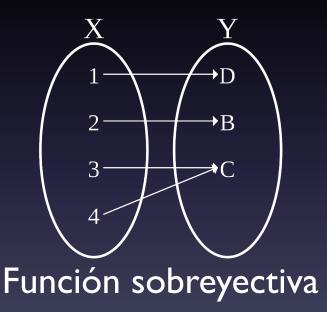
Posición en el fichero

- La función hash debería ser inyectiva. El problema es que encontrar una función así no es nada sencillo
- Cuando tenemos una función hash biyectiva decimos que tenemos una función hash perfecta. El conjunto de datos debe ser fijo y predeterminado





- Para el resto de casos tendremos funciones sobreyectivas, esto es, para algunas parejas de claves diferentes obtendremos el mismo valor. En este caso se producen colisiones en el valor de la función Hash
- Colisión: Dadas dos claves distintas, k₁ y k₂, si h(k₁)=h(k₂) se produce una colisión
- Dependiendo de cómo resolvamos esas colisiones tendremos hashing abierto o cerrado

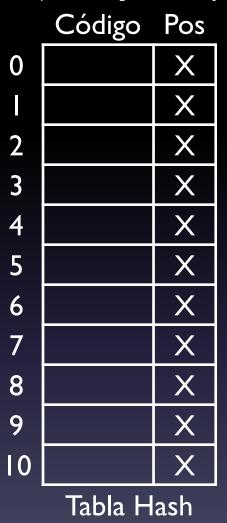


Esquema

Truncamiento Plegado Funciones Hash <u></u>Multiplicación Resto de la división Hashing abierto: Tabla Hash abierta Resolución de colisiones Hashing cerrado: Tabla Hash cerrada Rehashing lineal Rehashing doble

Ejemplo (sin colisiones)

M = 11 (primo más cercano a 8)



Código Apellidos

0	12	Abadía Ruiz	
	21	Bernabé Pérez	
2	68	Carrasco Ruiz	
3	38	Domingo Lucas	
4	52	Fernández Sánchez	
5	70	Jiménez Ruiz	
6	44	Martín Pérez	
7	18	Rodriguez Gómez	

Fichero

Tamaño: 8 registros

Ejemplo (sin colisiones)

• Funcionamiento:

Registro
$$0 = (12, Abadía Ruiz)$$

h(12) = 12%11 = 1

	Código	Pos
0		X
	12	0
•	•	•

	Codigo Apellidos							
0	12	Abadía Ruiz						
I	21	Bernabé Pérez						
•	•	•						
•	•	•						
•	•	•						

Cádigo Apollidas

		21						
h(k)	1	10	2	5	8	4	0	7

Ejemplo (sin colisiones)

	Código	Pos		
0	44	6		
	12	0		
2	68	2		
3		X		
4	70	5		
5	38	3		
6		X		
7	18	7		
8	52	4		
9		X		
10	21			
Tabla Hash				

	Código Apellidos					
0	12	Abadía Ruiz				
	21	Bernabé Pérez				
2	68	Carrasco Ruiz				
3	38	Domingo Lucas				
4	52	Fernández Sánchez				
5	70	Jiménez Ruiz				
6	44	Martín Pérez				
7	18	Rodriguez Gómez				

Ejemplo: consultas

- Si queremos obtener los datos del registro cuyo código es k = 52
 - a) h(52) = 52%11 = 8
 - b) Accedemos a la casilla 8 de la tabla Hash
 - c) Consultamos la posición del registro: 4
 - d) Accedemos a la posición en el fichero, recuperando la información: (52, Fernández Sánchez)
- Datos del registro con código k = 14
 - a) h(14) = 14%11 = 3
 - b) Casilla 3 vacía ⇒ registro inexistente

 $h: C \rightarrow Z$

- El dominio, C, corresponde al conjunto de posibles claves
- El rango, Z, es el conjunto de enteros positivos (puede contenter el 0), y corresponde al conjunto de índices sobre la tabla Hash

- La función Hash se debe definir de forma que
 - Sea rápida de calcular
 - Tome todos y cada uno de los posibles valores
 - Distribuya de forma lo más aleatoria posible las claves
 - Minimice el número de colisiones

I. Truncamiento: Consiste en eliminar algunos dígitos de la clave

$$h(123456789) = h(123456789) = 123$$

 $h(121567890) = h(121567890) = 121$

- Inconveniente: la tabla Hash debe tener un tamaño potencia de 10
- Alternativa: truncamiento a nivel interno (a nivel de bits).
 La tabla debe tener un tamaño potencia de 2

2. Plegado: Consiste en dividir una clave numérica en dos o más partes y sumarlas

$$h(\overline{123456}) = 123 + 456 = 579$$

Puede modificarse para que rote algún sumando

$$h(\overline{123456}) = 123 + 654 = 777$$

Puede combinarse con el truncamiento

$$h(\overline{456}882) = 456 + 882 = 1338 \Rightarrow \underline{1}338 = 338$$

Puede involucrar más de 2 sumandos

$$h(\overline{123456789}) = 123 + 456 + 789 = 1368$$

 Inconveniente: El tamaño de la tabla Hash debe ser potencia de 10

3. Multiplicación: Similar al plegado, pero en lugar de sumas, involucra productos. Puede haber plegado antes o después del producto

Ejemplo: Tabla de tamaño 10000 y claves de 9 dígitos $h(123456789) = 123 \times 789 = 97047 \Rightarrow 7047$

- Requiere tablas de tamaño potencia de 10
- Tiende a esparcir claves ⇒ menos colisiones
- Variantes:
 - Cuadrado del centro
 - Centro del cuadrado

Cuadrado del centro:

Seleccionar un cierto número de cifras del centro de la clave y calcular su cuadrado [+truncamiento]

$$h(123\underline{456}789) = 7936$$

 $456^2 = 207936 \implies 7936$

• Centro del cuadrado:

Calcular el cuadrado de la clave y seleccionar un cierto número de cifras del centro

$$h(1234) = 1234^2 = 1522756 = 2275$$

4. Resto de la división: Consiste en tomar el resto de la división de la clave entre el tamaño de la tabla (M) $h(k) = k \mod M \qquad (h(k) = k\%M)$

• Método muy simple que no requiere truncamiento

Ejemplo: h(k) = k%II

Claves: 12, 21, 68, 38, 52, 70, 44, 18

Rango: 0..10 (11 casillas)

- Consideraciones sobre el método del resto:
 - El tamaño de la tabla Hash debe ser, al menos, igual al número de claves posibles
 - La mejor elección es no tomar M simplemente par o impar, sino primo ⇒ M un número primo mayor que el número de claves

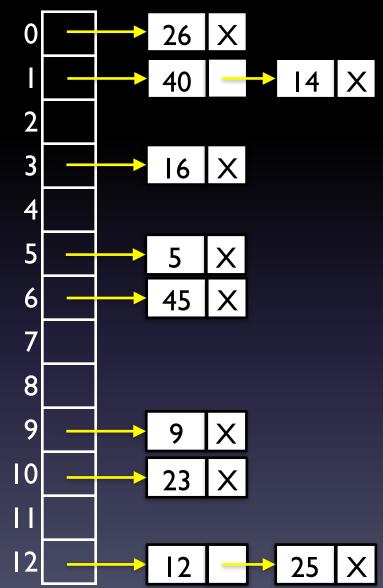
Tratamiento de colisiones

- Motivación: en la práctica totalidad de los casos, las funciones Hash provocan colisiones
- Objetivo: encontrar un mecanismo para la clave que provoca la colisión de forma que más tarde, en una operación de consulta, la búsqueda sea eficiente
- Alternativas para resolver las colisiones: dependen de la estructura de datos elegida
- En última instancia, depende de si conocemos de antemano o no el número de elementos a ubicar en la tabla Hash (o, al menos, una estimación)

- Consiste en construir para cada índice de la tabla una lista de claves sinónimas
 - Cada una de estas listas puede implementarse como una lista dinámica
- El tamaño de la tabla Hash se fija a priori y suele implementarse como un vector estático de punteros a estas listas
- Ventaja: La tabla puede tener un tamaño inferior al número de claves, ya que "crece" con memoria dinámica
- Desventaja: El espacio adicional requerido por los punteros necesarios para mantener las listas y la eficiencia de las operaciones sobre las listas

- Búsqueda: calculamos el valor hash de la clave y buscamos en la lista enlazada correspondiente
 - Si la inserción es LIFO o FIFO, se debe recorrer la lista completa
 - Si se inserta de forma ordenada, se reduce, en media, el tiempo de búsqueda (aunque la inserción es más costosa)
 - Búsqueda de clave inexistente: si se llega al final de la lista correspondiente y no se encuentra un nodo con la clave buscada

- Las colisiones se resuelven insertándolas en una lista
- La ED resultante es un vector de listas
- Factor de carga: número medio de claves por lista
- Objetivo: que el factor de carga esté próximo a I
- Ejemplo: 23,45,16,26,40,14,5,12,9,25con h(x) = x%13



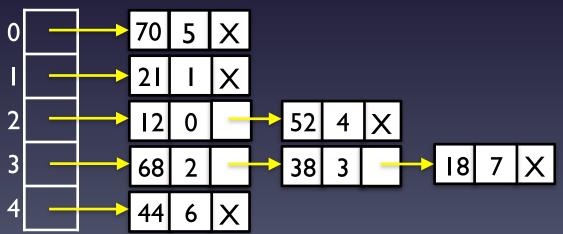
k	12	21	68	38	52	70	44	18
h(k)	2		3	3	2	0	4	3

$$h(k) = k\%M, con M = 5$$

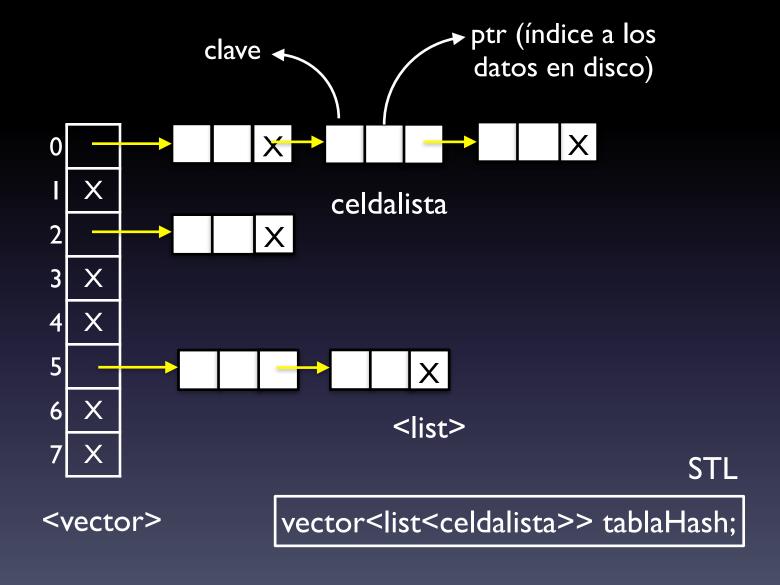
Código Apellidos

0	12	Abadía Ruiz			
	21	Bernabé Pérez			
2	68	Carrasco Ruiz			
3	38	Domingo Lucas			
4	52	Fernández Sánchez			
5	70	Jiménez Ruiz			
6	44	Martín Pérez			
7	18	Rodriguez Gómez			

Fichero



Clase Tabla Hash abierta



Hashing cerrado

- Usamos un vector para alojar la tabla Hash
- Rehashing: Cuando se produzca colisión, la resolvemos asignándole otro valor hash a la clave hasta encontrar un hueco

- Estrategias:
 - Rehashing lineal
 - Sondeo aleatorio
 - Hashing doble

Hashing cerrado

- Las búsquedas se hacen siguiendo la misma secuencia de la función hash usada para la inserción
- ¡¡Cuidado con los borrados!! La casilla puede formar parte de una cadena de búsqueda
 - La casilla debe marcarse como borrada, un estado diferente al de libre u ocupada
- Diferencia entre casilla libre y borrada:
 - Inserción: borrada y libre son equivalentes (disponemos de un hueco)
 - Búsqueda: borrada y ocupada son equivalentes (seguimos el proceso de búsqueda)

Hashing cerrado. Redimensionamiento

- Redimensionamiento de la tabla Hash
 - Consiste en volver a construir la tabla Hash con un nuevo tamaño, y volver a hacer hashing (y, eventualmente, rehashing) de todas las claves de la tabla antigua (la función Hash cambia al cambiar M)
 - Debe realizarse cuando la tabla hash se desborda (se llena) o cuando su eficiencia decaiga demasiado debido a inserciones y borrados

- Rehashing lineal: $h_i(k) = [h(k) + (i-1)] \% M$, i=2,3...
- Estrategia:
 - Si se evalúa h(k) para una clave k y hay colisión
 - Generamos la secuencia de valores h₂(k), h₃(k)... mientras se mantenga el estado de colisión
 - Cuando para un t, $h_t(k)$ no se produzca colisión, se termina la secuencia de rehashing y ubicamos la clave en $h_t(k)$
- Podemos reescribir la función de rehashing lineal como

$$\begin{cases} h_i(k) = [h_{i-1}(k) + 1] \% M, & i=2,3... \\ h_0(k) = h(k) \end{cases}$$

Ejemplo: 23,45,16,26,40,14,5,12,9,25 con h(x) = x%13

k	23	45	16	26	40	14	5	12	9	25
h(k)	10	6	3	0	1	1	5	12	9	12

O: Casilla ocupada

L: Casilla libre

	Clave	Posición	Status
0	26	pos	0
	40	pos	O
2	14	pos	0
3	16	pos	0
4	25	pos	O
5	5	pos	O
6	45	pos	O
7			L
8			L
9	9	pos	O
10	23	pos	O
П			L
12	12	pos	O

• Ejemplo: h(x) = x%13

k	Registro	h(k)
119	0	2
85		7
43	2	4
141	3	
72	4	8
91	5	0
109	6	5
147	7	6
38	8	12
137	9	9
148	10	
101	Ш	

$$h(72) = 7$$

 $h_2(72) = (7+(2-1))\%13 = 8$

$$h(147) = 4$$

 $h_2(147) = (4+(2-1))\%13 = 5$
 $h_3(147) = (4+(3-1))\%13 = 6$

$$h(137) = 7$$

 $h_2(137) = (7+(2-1))\%13 = 8$
 $h_3(147) = (7+(3-1))\%13 = 9$

O: Casilla ocupada

L: Casilla libre

	Clave	Posición	Status
0	91	5	O
			L
2	119	0	O
3			L
4	43	2	O
5	109	6	O
6	147	7	O
7	85		O
8	72	4	0
9	137	9	O
10			L
П	141	3	O
12	38	8	O

• Ejemplo: h(x) = x%13

k	Registro	h(k)
119	0	2
85		7
43	2	4
141	3	
72	4	8
91	5	0
109	6	5
147	7	6
38	8	12
137	9	9
148	10	10
101	П	

$$h(148) = 5$$

$$h_2(148) = (5+(2-1))\%13 = 6$$

$$h_3(148) = (5+(3-1))\%13 = 7$$

$$h_4(148) = (5+(4-1))\%13 = 8$$

$$h_5(148) = (5+(5-1))\%13 = 9$$

$$h_6(148) = (5+(6-1))\%13 = 10$$

$$h(101) = 10$$

$$h_2(101) = (10+(2-1))\%13 = 11$$

$$h_3(101) = (10+(3-1))\%13 = 12$$

$$h_4(101) = (10+(4-1))\%13 = 0$$

$$h_5(101) = (10+(5-1))\%13 = 1$$

O: Casilla ocupada

L: Casilla libre

	Clave	Posición	Status
0	91	5	O
	101		O
2	119	0	O
3			L
4	43	2	O
5	109	6	0
6	147	7	O
7	85		O
8	72	4	O
9	137	9	O
10	148	10	0
П	141	3	O
12	38	8	0

• Ejemplo: h(x) = x%13

k	Registro	h(k)	Rendimiento
119	0	2	I
85		7	I
43	2	4	
141	3		
72	4	8	2
91	5	0	I
109	6	5	
147	7	6	3
38	8	12	
137	9	9	3
148	10	10	6
101	Ш		5
			26

	101	Ш	0
2	119	0	O
3			L
4	43	2	0
5	109	6	0
6	147	7	0
7	85		0
8	72	4	0
9	137	9	0
10	148	10	0
Ш	141	3	0
12	38	8	O

Clave Posición Status

5

O

O: Casilla ocupada

L: Casilla libre

- El rehashing lineal tiende a crear agrupaciones primarias
- Una agrupación primaria es una sucesión de casillas ocupadas en una tabla Hash a distancia I (contiguas)
- Las agrupaciones primarias conllevan largas series de búsqueda que degradan la eficiencia de las inserciones y los borrados

0 | 2 | 3 | 4 | 5 | 6 | 7 | 8 | 9 | 10 | 11 | 12

Inserción de la clave 72:

Inserción de las claves 91 y 109:

Inserción de la clave 147:

- 0 1 2 3 4 5 6 7 8 9 10 11 12
- 0 1 2 3 4 5 6 7 8 9 10 11 12

Inserción de la clave 38:

- 0 I 2 3 4 5 6 7 8 9 I0 II I2 1
- 0 1 2 3 4 5 6 7 8 9 10 11 12

38

Inserción de la clave 137:





Inserción de la clave 148:





Inserción de la clave 101:



- Soluciones ante la aparición de agrupaciones primarias:
 - Mantener estructuras de datos auxiliares que mantengan información (inicio y fin) de las agrupaciones primarias, de forma que se pueda acceder directamente a los "huecos"
 - Buscar otros métodos que distribuyan las casillas vacías de forma más aleatoria (al fin y al cabo, la idea del Hashing es la distribución "aleatoria" de claves)

Rehashing lineal. Algoritmo de búsqueda

```
I. Calcular h(k)
2. Si (no borrada(h(k)) && clave(h(k)) == k)
      posicion = registro(h(k))
   Si no,
     Repetir
       h_i(k) = rehashing(h_{i-1}(k))
     hasta que (no borrada(h(k)) && (clave(h<sub>i</sub>(k))=k || vacia(h<sub>i</sub>(k))))
   Si (clave(h_i(k)) == k)
     posicion = registro(h_i(k))
   Si no, posicion = -1
3. Devolver (posicion)
```

$$h_i(k) = (h(k) + (i-1) * C) % M, i=2, 3, ...$$

 $h_i(k) = [h_{i-1}(k) + C] % M, i=2, 3, ...$

donde

- h(k) es el valor de la función Hash
- M es el tamaño de la tabla
- C>I y es primo relativo con M

• Ejemplo: h(x) = x%13

k	Registro	h(k)
119	0	2
85		7
43	2	4
141	3	
72	4	12
91	5	0
109	6	5
147	7	9
38	8	
137	9	
148	10	
101	Ш	

$$h(72) = 7$$

 $h_2(72) = (7+(2-1) * 5)\%13 = 12$

$$h(147) = 4$$

 $h_2(147) = (4+(2-1)*5)\%13 = 9$

$$h(38) = 12$$

$$h_2(38) = (12+(2-1)*5)\%13 = 4$$

$$h_3(38) = (12+(3-1)*5)\%13 = 9$$

$$h_4(38) = (12+(4-1)*5)\%13 = 1$$

O: Casilla ocupada

L: Casilla libre

	Clave	Posición	Status
0	91	5	0
	38	8	0
2	119	0	O
3			L
4	43	2	O
5	109	6	0
6			L
7	85		0
8			L
9	147	7	0
10			L
П	141	3	0
12	72	4	0

• Ejemplo: h(x) = x%13

k	Registro	h(k)
119	0	2
85		7
43	2	4
141	3	Ш
72	4	12
91	5	0
109	6	5
147	7	9
38	8	
137	9	6
148	10	10
101	Ш	

$$h(137) = 7$$

$$h_2(137) = (7+(2-1)*5)\%13 = 12$$

$$h_3(137) = (7+(3-1)*5)\%13 = 4$$

$$h_4(137) = (7+(4-1)*5)\%13 = 9$$

$$h_5(137) = (7+(5-1)*5)\%13 = 1$$

$$h_6(137) = (7+(6-1)*5)\%13 = 6$$

$$h(148) = 5$$

 $h_2(38) = (5+(2-1)*5)\%13 = 10$

O: Casilla ocupada

L: Casilla libre

	Clave	Posición	Status
0	91	5	O
	38	8	0
2	119	0	O
3			L
4	43	2	0
5	109	6	0
6	137	9	0
7	85		0
8			L
9	147	7	0
10	148	10	0
Ш	141	3	0
12	72	4	0

• Ejemplo: h(x) = x%13

k	Registro	h(k)
119	0	2
85		7
43	2	4
141	3	
72	4	12
91	5	0
109	6	5
147	7	9
38	8	
137	9	6
148	10	10
101		3

h(101) = 10
$h_2(101) = (10+(2-1)*5)\%13 = 2$
$h_3(101) = (10+(3-1)*5)\%13 = 7$
$h_4(101) = (10+(4-1)*5)\%13 = 12$
$h_5(101) = (10+(5-1)*5)\%13 = 4$
$h_5(101) = (10+(5-1)*5)\%13 = 9$
$h_5(101) = (10+(5-1)*5)\%13 = 1$
$h_5(101) = (10+(5-1)*5)\%13 = 6$
$h_5(101) = (10+(5-1)*5)\%13 = 11$
$h_6(101) = (10+(6-1)*5)\%13 = 3$

O: Casilla ocupada L: Casilla libre

	Clave	Posición	Status
0	91	5	0
	38	8	O
2	119	0	O
3	101	П	0
4	43	2	O
5	109	6	O
6	137	9	O
7	85		O
8			L
9	147	7	0
0	148	10	0
I	141	3	0
2	72	4	0

• Ejemplo: h(x) = x%13

k	Registro	h(k)	Rendimiento
119	0	2	
85		7	
43	2	4	
141	3		
72	4	12	2
91	5	0	
109	6	5	
147	7	9	2
38	8		4
137	9	6	6
148	10	10	2
101		3	10
			33

Problema:

Agrupaciones secundarias de orden C

	Clave	Posición	Status
0	91	5	0
	38	8	O
2	119	0	0
3	101		0
4	43	2	0
5	109	6	0
6	137	9	L
7	85		0
8			L
9	147	7	0
10	148	10	L
П	141	3	0
12	72	4	0

Hashing cerrado. Rehashing doble

$$h_i(k) = (h_{i-1}(k) + h_0(k)) \% M i = 2, 3, ...$$

$$h_0(k) = 1 + (k\%(M-2))$$

 $h_1(k) = h(k)$

- Puede haber otras elecciones de $h_0(k)$, siempre que no sea constante y distinta de 0
- Buena cuando M y M-2 son primos relativos

• Ejemplo: h(x) = x%13

k	Reg	h _I (k)	h ₀ (k)
119	0	2	10
85		7	9
43	2	4	Ш
141	3	Ш	10
72	4	7	7
91	5	0	4
109	6	5	Ш
147	7	4	5
38	8	12	6
137	9	7	6
148	10	5	6
101	Ш	10	3

h(119) = 2
h(85) = 7
h(43) = 4
h(141) = 11
h(72) = 7
$h_2(72) = (h_1(72) + h_0(72))\% I3 =$
= (7+7)%13 = 1
h(91) = 0
h(109) = 5
h(147) = 4
$h_2(147) = (h_1(147) + h_0(147))\%13 =$
= (4+5)%13 = 9
h(38) = 12

O: Casilla ocupada L: Casilla libre

	Clave	Posición	Status
0	91	5	0
	72	4	0
2	119	0	0
3			L
4	43	2	0
5	109	6	0
6			L
7	85		0
8			L
9	147	7	0
0			L
	141	3	0
2	38	8	O

• Ejemplo: h(x) = x%13

k	Reg	h _I (k)	$h_0(k)$
119	0	2	10
85		7	9
43	2	4	Ш
141	3	Ш	10
72	4	7	7
91	5	0	4
109	6	5	Ш
147	7	4	5
38	8	12	6
137	9	7	6
148	10	5	6
101	Ш	10	3

h(137) = 7
$h_2(137) = (h_1(137) + h_0(137))\%13 =$
= (7+6)%13 = 0
$h_3(137) = (h_2(137) + h_0(137))\%13 =$
= (0+6)%13 = 6
h(148) = 5
$h_2(148) = (h_1(148) + h_0(148))\%13 =$
= (5+6)%13 = 11
$h_3(148) = (h_2(148) + h_0(148))\%13 =$
= (11+6)%13 = 4
$h_4(148) = (h_3(148) + h_0(148))\%13 =$
= (4+6)%13 = 10
h(101) = 10
$h_2(101) = (h_1(101) + h_0(101))\%13 =$
= (10+3)%13 = 0
$h_3(101) = (h_2(101) + h_0(101))\%13 =$
(0.2)0/12

	Clave Posición Status				
0	91	5	0		
	72	4	0		
2	119	0	0		
3	101		0		
4	43	2	0		
5	109	6	0		
6	137	9	0		
7	85		0		
8			L		
9	147	7	0		
0	148	10	0		
I	141	3	0		
2	38	8	0		

• Ejemplo: h(x) = x%13

k	Reg	h _I (k)	h ₀ (k)	Rendimiento
119	0	2	10	
85		7	9	
43	2	4	Ш	
141	3	Ш	10	
72	4	7	7	2
91	5	0	4	
109	6	5	Ш	
147	7	4	5	2
38	8	12	6	
137	9	7	6	3
148	10	5	6	4
101	Ш	10	3	3
			21	

	Clave	Posición	Status
0	91	5	0
	72	4	0
2	119	0	0
3	101		0
4	43	2	0
5	109	6	0
6	137	9	0
7	85		0
8			L
9	147	7	0
0	148	10	0
	141	3	0
2	38	8	0